Прогноз покупки по сессии интернет-магазина

Итоговый проект по дисциплине «Разведочный анализ и алгоритмы классификации»

Подольский Филипп · магистратура ПМИ, ФМИ ПГНИУ

Датасет: UCI Online Shoppers Purchasing Intention · 2026

Цель и задачи

Цель

Отличать сессии, которые закончатся покупкой, от остальных, объяснить, на чём основан прогноз, и дать к результатам интерактивный доступ.

Бинарная классификация Revenue: 1 — покупка, 0 — нет

1. **Разведочный анализ**
   общее исследование, однофакторный анализ, пары факторов
2. **Подготовка признаков**
   one-hot, log1p, масштабирование, разбиение
3. **Модели классификации**
   8 вариантов, кросс-валидация, выбор порога
4. **Интерпретация**
   словами о качестве, SHAP, отдельные прогнозы
5. **Развёртывание**
   дашборд в Docker, запуск одной командой

Данные и их качество

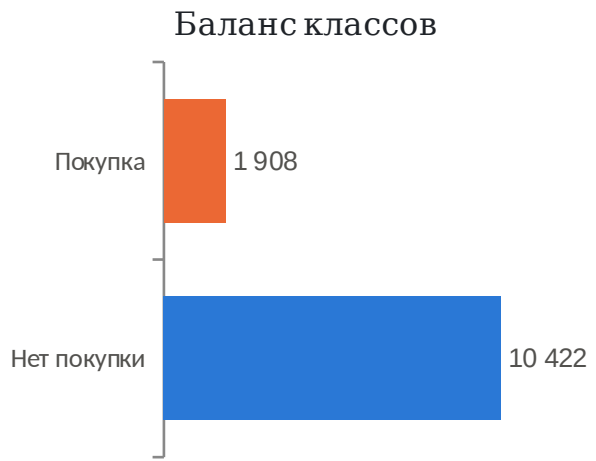
12 330
сессий (строк)

17
признаков + Revenue

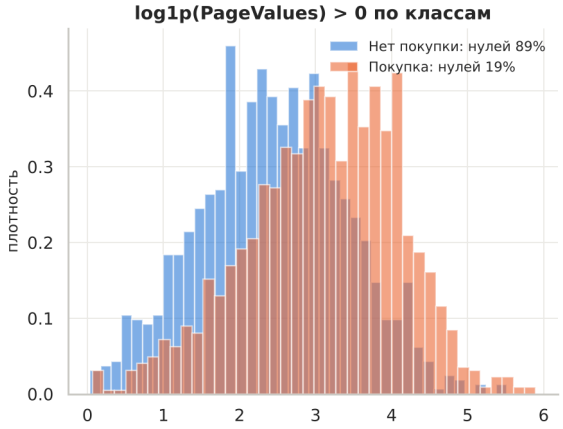
15,5 %
сессий с покупкой

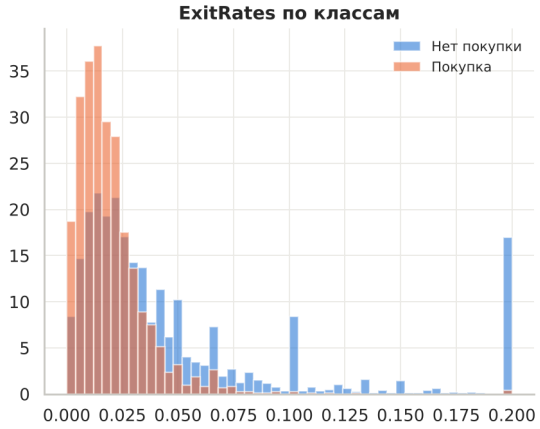
0
пропусков

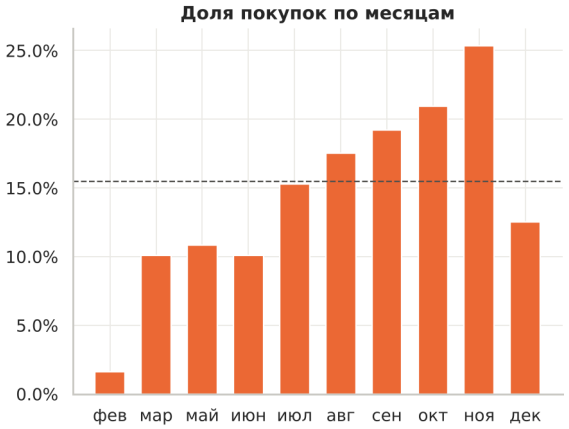
- 10 числовых: счётчики страниц и время на них, метрики Google Analytics (BounceRates, ExitRates, PageValues), SpecialDay
- OperatingSystems, Browser, Region, TrafficType — целые коды без порядка, т. е. номинальные признаки
- Счётчики и длительности сильно скошены, много нулей; 125 полных дубликатов — одностраничные сессии
- В данных 10 месяцев: нет января и апреля



Однофакторный анализ

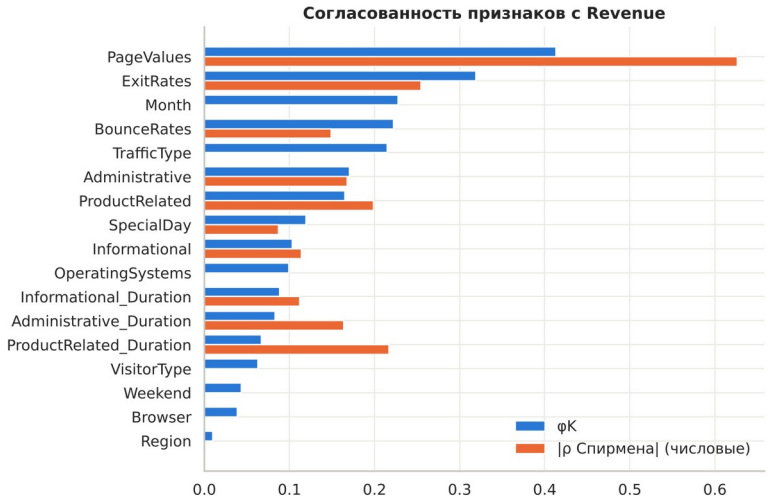


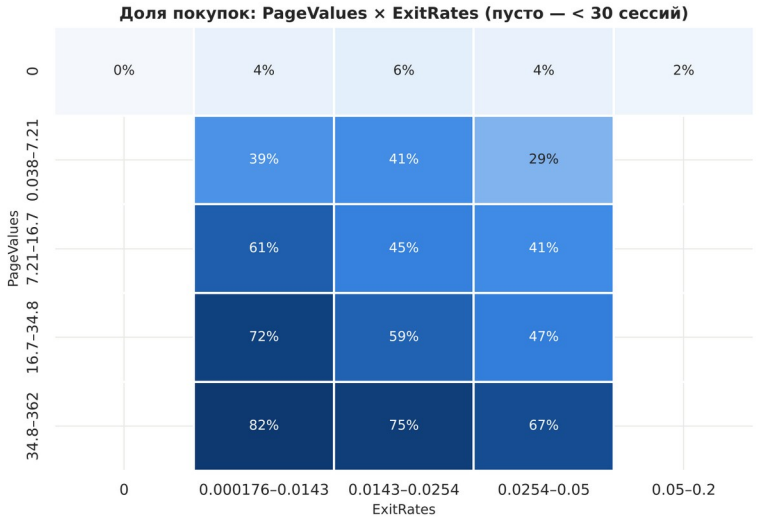




- PageValues > 0 у 80,6 % сессий с покупкой и у 11,4 % без неё; среди сессий с PageValues = 0 покупок 3,9 %
- ExitRates в классе «покупка» ниже: медиана 0,016 против 0,029
- Доля покупок по месяцам — от 1,6 % (февраль) до 25,4 % (ноябрь); по Region различий нет (χ^2, p = 0,32)

Корреляции и пары факторов

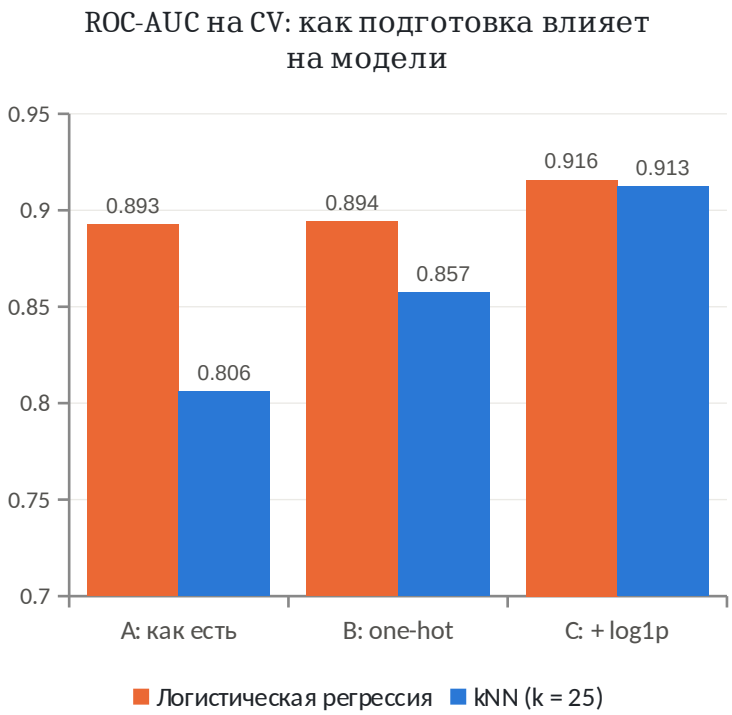




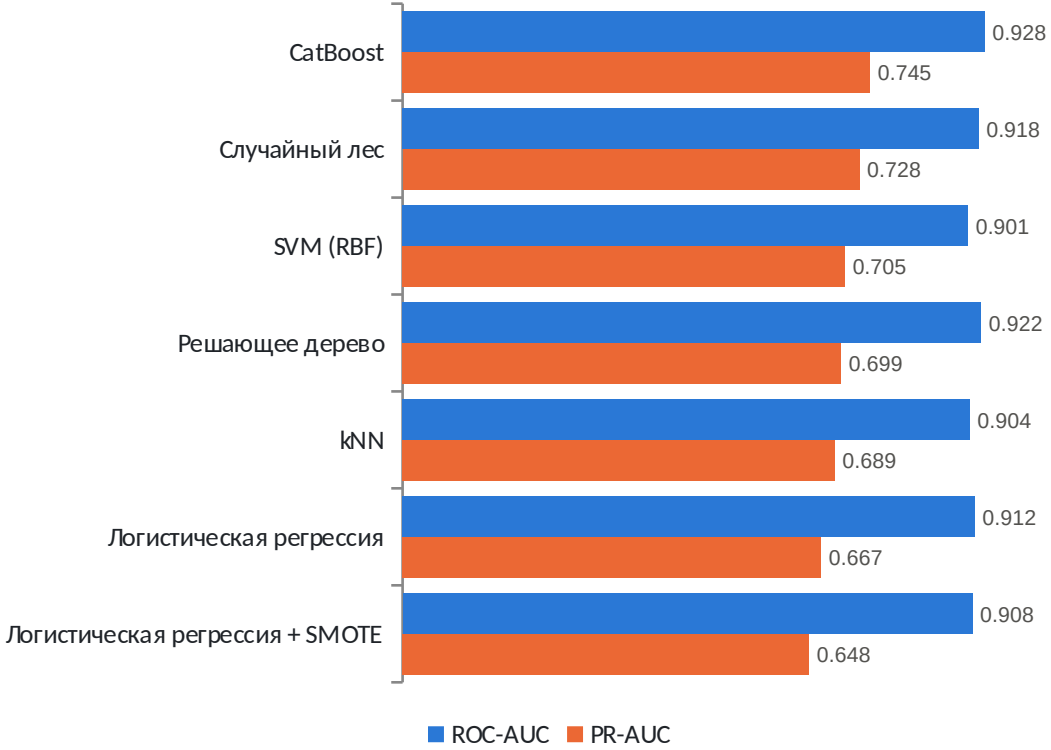
- Пирсон на скошенных данных вводит в заблуждение: «страницы — время» r = 0,60 при ρ Спирмена = 0,94
- С Revenue сильнее всего согласован PageValues (φK = 0,41), затем ExitRates (0,32), Month, BounceRates, TrafficType
- PageValues × ExitRates: доля покупок от 0–6 % (PageValues = 0) до 82 % (высокий PageValues, низкий ExitRates)

Подготовка признаков

Признаки	Преобразование
Month, VisitorType, коды ОС, браузера, региона, трафика	one-hot; категории реже 1 % → other
Счётчики, длительности, PageValues	log1p + стандартизация (kNN, ЛР, SVM); без изменений для деревьев
BounceRates, ExitRates, SpecialDay	стандартизация (SpecialDay — единственный порядковый признак)
Weekend, Revenue	0 / 1
Выбросы и дубликаты	оставлены: реальные сессии, не ошибки



Сравнение моделей (тест)



Финальная — CatBoost

Лидеры на CV — CatBoost и случайный лес: PR-AUC 0,741 и 0,748 при разбросе ±0,02, т. е. неразличимы

У CatBoost лучше ROC-AUC и калибровка; в финальной версии без весов классов

Веса классов и SMOTE PR-AUC не улучшили — дисбаланс учтён порогом

Качество финальной модели

0,929
ROC-AUC (0,5 — случайная)

0,744
PR-AUC (0,155 — случайная)

75 %
покупок найдено (recall)

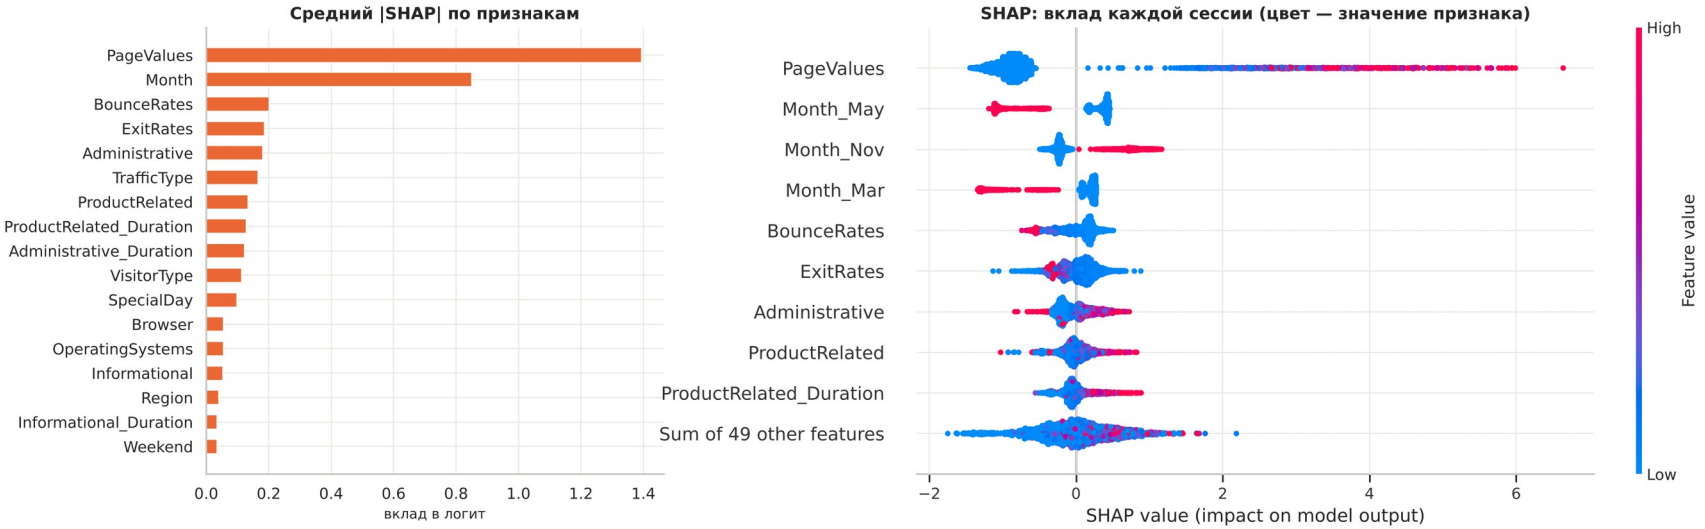
61 %
верных среди отмеченных

порог 0,27	прогноз: нет	прогноз: покупка
факт: нет	1904	180
факт: покупка	96	**286**

Матрица ошибок на тестовой выборке (2 466 сессий)

- Модель ранжирует сессии хорошо: в 93 случаях из 100 сессия с покупкой получает балл выше, чем сессия без покупки
- Среди отмеченных моделью покупка встречается в 61 % случаев — в 4,0 раза чаще среднего: для таргетинга предложений это хорошо
- Но 96 из 382 покупок пропущено — как «точный прогноз каждой покупки» модель недостаточна

На чём основан прогноз



- Главные признаки по SHAP: PageValues, Month, BounceRates, ExitRates, Administrative
- Высокий PageValues сдвигает прогноз к покупке, высокий ExitRates и BounceRates — от неё; ноябрь повышает вероятность, март и май — понижают
- Без PageValues качество падает: ROC-AUC 0,765, PR-AUC 0,355 — модель во многом опирается на метрику GA, связанную с историей транзакций

Дашборд в Docker и итоги

Запуск одной командой

```
docker compose up --build
```

→ http://localhost:9050

- О проекте: метрики и сравнение моделей
- Разведочный анализ: признак, пара признаков, корреляции
- Важность признаков, качество модели
- Отдельные прогнозы, «что если», SHAP

Итоги

- Проведён EDA по схеме курса: общее исследование → однофакторный → пары факторов, без преждевременных выводов
- Обоснована подготовка признаков: one-hot для номинальных, log1p и масштабирование там, где это нужно модели
- Лучшая модель — CatBoost: ROC-AUC 0,929, PR-AUC 0,744; качество и прогнозы объяснены через SHAP
- Ограничение: сильная зависимость от PageValues и нет данных за январь и апрель